

Estatística e Probabilidade

Bacharelado em Sistemas de Informação

Aula 1: Coleta e organização de dados ______ Prof. Dr. Samuel Sanches



APRESENTAÇÃO

★ Prof. Dr. Samuel Sanches

★ e-mail: samuel.msjunior@sp.senac.br



APRESENTAÇÃO DA DISCIPLINA

★ Conteúdo:

- Apresenta noções de estatística descritiva;
- o probabilidade;
- variáveis aleatórias;
- inferência estatística;
- o interpretar os principais procedimentos estatísticos descritivos;
- o estabelecer relações entre a estatística e as atividades ligadas à área de atuação.
- ★ **Objetivo**: <u>Geral</u>: utilizar conceitos de estatística e teoria da probabilidade para explorar, resumir, estimar e analisar dados para apoio à tomada de decisão. <u>Específicos</u>: capacitar o aluno a descrever dados e reconhecer as principais distribuições para realizar inferências e predições de modo a obter conclusões, utilizando ferramentas de mercado.



BIBLIOGRAFIA

★ Básica

- o BUSSAB, W. de O.; MORETTIN, P. A. Estatística básica. São Paulo: Saraiva, 2002.
- LARSON, R.; FARBER, B. Estatística aplicada. São Paulo: Pearson Education do Brasil, 2015.
 E-book.
- MAGALHÃES, M. N.; LIMA, C. P. de. Noções de probabilidade e estatística. São Paulo: Edusp, 2002.

★ Complementar

- BERTHOUEX, P. M.; BROWN, L. C. Statistics for environmental engineers. Boca Raton: Lewis Publishers, 2002.
- o FONSECA, J. S. da; MARTINS, G. A. Curso de estatística. São Paulo: Atlas, 1982.
- LEVINE, D. M.; BERENSON, M. L.; STEPHAN, D. Estatística: teoria e aplicações. Rio de Janeiro: LTC, 2000.
 LOPES, P. A. Probabilidades & estatística: conceitos, modelos e aplicações em Excel. Rio de Janeiro:
- LOPES, P. A. Probabilidades & estatística: conceitos, modelos e aplicações em Excel. Rio de Janeiro: Reichmann & Affonso Editores, 1999.
- o MARTINS, G. de A. Estatística geral e aplicada. São Paulo: Atlas, 2002.



AVALIAÇÕES

 \star MF = 0,6 * MP + 0,4 * MA.

MF = média final.

MP = média aritmética das avaliações individuais [(P1+P2)/2]. A nota da avaliação substitutiva poderá ser usada no lugar de uma das avaliações individuais.

MA = média aritmética de atividades (ADOs).



★ Quando surgiu?

★ É importante?

★ Onde a encontramos?

★ Devemos conhecer, estudar e utilizar?



★ Quando de fato, começa a utilização da estatística em uma pesquisa?

★ **Exemplo**: Para determinar a reação do público à continuação de certo programa governamental, o pesquisador pergunta: "Você acha que esse programa esbanjador deve ser continuado?"

Existe algum problema nessa pergunta?



★ Quando de fato, começa a utilização da estatística em uma pesquisa?

★ **Exemplo**: Para determinar a reação do público à continuação de certo programa governamental, o pesquisador pergunta: "Você acha que esse programa esbanjador deve ser continuado?"

Existe algum problema nessa pergunta?

Na pergunta, já está implícito que esse programa é esbanjador, ou seja, estamos induzindo o entrevistado, provavelmente a resposta não será respondida com honestidade.



- ★ Quando de fato, começa a utilização da estatística em uma pesquisa?
- ★ Exemplo: Para estudar a reação do consumidor a um novo tipo de alimento congelado, faz-se uma pesquisa de casa em casa durante as manhãs dos dias úteis, sem previsão de retornar no caso de ninguém atender.

Existe algum problema nesse estudo?



★ Quando de fato, começa a utilização da estatística em uma pesquisa?

Exemplo: Para estudar a reação do consumidor a um novo tipo de alimento congelado, faz-se uma pesquisa de casa em casa durante as manhãs dos dias úteis, sem previsão de retornar no caso de ninguém atender.

Existe algum problema nesse estudo?

A pesquisa provavelmente não irá atingir os possíveis consumidores, já que o público alvo provavelmente são pessoas que trabalham o dia inteiro e não tem tempo para cozinhar, ou seja, não estarão em casa nesse horário.



ESTATÍSTICA DESCRITIVA

- ★ Governos: recenseamentos (atualização de dados).
- ★ Descrever, resumir e analisar.
- ★ Utilização dos valores centrais e de tabelas e gráficos.
- ★ **Exemplo**: Conjunto de 6 carros de todos importados, constatou-se que eles aceleram de 0 a 60 km/h em 12,9; 16,5; 11,3; 15,2; 18,2 e 17,7 segundos, ou seja, metade acelera em menos de 16 s, calculando a média desses valores temos 15,3 s, mas não podemos concluir que metade deles aceleram em menos que 16 s.



INFERÊNCIA ESTATÍSTICA

- ★ Utilizamos para fazer generalizações.
- **Exemplo**: Estimar o tempo de vida de um equipamento eletrônico; Qual será o tráfego em uma rodovia que será construída; Qual a melhor dosagem de certo medicamento; etc.
- ★ Todos possuem incertezas (chances)!
- ★ Jogos de azar.
- ★ Teoria de Probabilidade



NATUREZA DOS DADOS

- ★ Dados numéricos (quantitativos) e Dados categóricos (qualitativos, que normalmente são codificados, estado civil, 0, 1, 2, etc).
- ★ **Dados nominais**, como o estado civil em que os dados nominais são nomes de números, ou seja, não podemos dizer 0 > 1, deve-se sempre estar atento ao tratamento matemático!
- \bigstar **Dados ordinais**, somente podemos atribuir desigualdades (<, >, \geq , \leq).
- ★ Dados intervalares, somente diferenças (desigualdades e igualdades podem, não podemos multiplicar nem dividir, exemplo, temperaturas).
- ★ Dados de razão, pode-se formar quociente, entram quaisquer medidas, comprimento, densidade, etc.



RESUMINDO DADOS

- ★ **Domo**: infográfico sobre a quantidade mundial de dados gerados e na sua última versão, foi estimado 3,1 mil terabytes gerados por segundo.
- ★ Tabelas ou gráficos que eram muito de um curso! Muito utilizada hoje em dia, temos isso a todo instante. Não saber interpretar pode te enganar!
- ★ Problema: Correlação X Causalidade

Domo: https://www.domo.com/data-never-sleeps

Como as estatísticas podem ser enganosas: https://youtu.be/sxYrzzy3cq8

Como mentir com estatísticas: https://estatir.com.br/2021/11/19/como-mentir-com-estatistica/

Diferença correlação e causalidade:

https://gec.proec.ufabc.edu.br/o-que-que-a-ciencia-tem/qual-a-diferenca-entre-correlacao-e-causalidade/?lang=en



★ Após a coleta dos dados é necessária sua organização para melhor compreensão. Como **exemplo**, veja os dados abaixo, que são as massas em kg de 60 malas despachadas em uma companhia aérea:

19,2	19,6	17,3	19,3	19,5	20,4	23,5	19,0	19,4	18,4
19,4	21,8	20,4	21,0	21,4	19,8	19,6	21,5	20,2	20,1
20,3	19,7	19,5	22,9	20,7	20,3	20,8	19,8	19,4	19,3
19,5	19,8	18,9	20,4	20,2	21,5	19,9	21,7	19,5	20,9
18,1	20,5	18,3	19,5	18,3	19,0	18,2	21,9	17,0	19,7
20,7	21,1	20,6	16,6	19,4	18,6	22,7	18,5	20,1	18,6



★ Uma informação interessante são os extremos, nesse exemplo são 16,6 e 23,5. Assim, a ordem crescente (ou decrescente) pode ser útil (organizar manualmente é trabalhoso, com uma planilha: selecionar, Dados -> Classificar intervalo -> Classificar de A a Z):

16,6	17,0	17,3	18,1	18,2	18,3	18,3	18,4	18,5	18,6
18,6	18,9	19,0	19,0	19,2	19,3	19,3	19,4	19,4	19,4
19,4	19,5	19,5	19,5	19,5	19,5	19,6	19,6	19,7	19,7
19,8	19,8	19,8	19,9	20,1	20,1	20,2	20,2	20,3	20,3
20,4	20,4	20,4	20,5	20,6	20,7	20,7	20,8	20,9	21,0
21,1	21,4	21,5	21,5	21,7	21,8	21,9	22,7	22,9	23,5

Planilha Aula 1:



- **Exemplo**: Uma auditoria de 20 declarações de imposto de renda revelou 0, 2, 0, 0, 1, 3, 0, 0, 0, 1, 0, 0, 2, 1, 0, 0, 1 e 0 erros de cálculos.
- a) Construa uma tabela mostrando o número de declarações com 0, 1, 2 e 3 erros de cálculos.
- b) Esboce um diagrama de pontos exibindo a mesma informação.



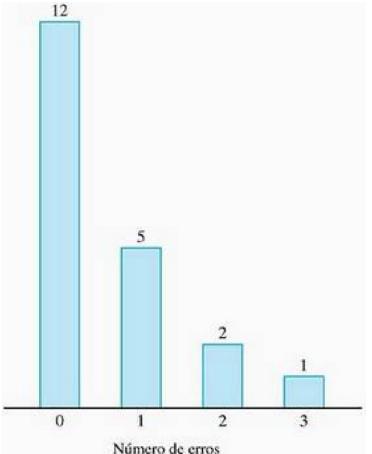
Exemplo (solução): Contando o número de números 0, 1, 2 e 3, temos 12, 5, 2 e 1, respectivamente. Podemos montar uma tabela e uma forma

gráfica:

Número de erros	Número de restrições	:			
0	12	:			
1	5	•			
2	2	•			
3	1	•	•		
		•	•	•	
		•	•	•	•
		0	1 Núme err		3



★ Exemplo (solução): Contando o número de números 0, 1, 2 e 3, temos 12, 5, 2 e 1, respectivamente. Também podemos montar um gráfico de barras:





★ Exemplo: O corpo docente do departamento de Economia de uma universidade consiste em três professores titulares, seis professores adjuntos, doze professores assistentes e oito professores substitutos. Disponha essa informação na forma de diagrama de pontos alinhados horizontalmente.

Níveis dos professo	res
Titular	***
Adjunto	*****
Assistente	******
Substituto	******



★ Quando temos muitos valores ou diferentes categorias ou valores muito altos, pode-se utilizar esse diagrama, que acaba perdendo a informação da ordem em que os dados foram obtidos. Como **exemplo**, veja os dados de quartos ocupados em um hotel de praia em janeiro:

55	49	37	57	46	40	64	35	73	62
61	43	72	48	54	69	45	78	46	59
40	58	56	52	49	42	62	53	46	81



★ Podemos agrupá-los pelas dezenas, ou seja, os que começam com 3, 4 e assim por diante:

37	35									
49	46	40	43	48	45	46	40	49	42	46
55	57	54	59	58	56	52	53			
64	62	61	69	62						
73	72	78								
81										



★ Então, para melhor adequar, separamos as dezenas, assim, cada linha é denominada ramo e cada número à esquerda da linha vertical é o rótulo do ramo e cada número à direita é denominado folha, ainda organizamos em ordem crescente:

3	5	7									
4	0	0	2	3	5	6	6	6	8	9	9
	11000	3									
6	1	2	2	4	9						
7	2	3	8								
8	1										



★ Podemos dividir os que possuem muitas folhas, assim temos o diagrama de ramos e folhas duplos:



★ Rótulos podem ter 2 dígitos, valores, 240, 242, 245, 248 e 249:

★ Ou só 1, valores, 231, 245, 270 e 288:

```
2 | 31 45 70 88
```



★ Quando temos muitos dados crus, um tratamento é organizá-los pela frequência de vezes em que ele aparece. Exemplo: Num levantamento foram obtidas as movimentações financeiras de 4757 escritórios (distribuição numérica ou quantitativa):

Movimento total	Número de escritórios de advocacia
Menos do que 300.000 unidades monetárias	2.405
300.000 a 499.999 unidades monetárias	1.088
500.000 a 749.999 unidades monetárias	271
750.000 a 999.999 unidades monetárias	315
Mais do que 1.000.000 unidades monetárias	678
Total	4.757



Exemplo: Quantidade de queixas de passageiros contra companhias aéreas (distribuição categórica ou qualitativa):

Tipo de queixa	Número de queixas
Cancelamento e atraso de vôo	1.586
Atendimento ao cliente	805
Problemas com bagagem	761
Bilhetes e check-in	598
Devoluções	393
Turbulência	301
Informações sobre tarifas	267
Outras	468
Total	5.179



- Para construção:
 1) Escolher as classes (intervalos ou categorias)
 2) Separar ou enquadrar os dados nessas classes
 3) Contar o número de itens de cada classe
- Raramente temos menos do que 5 ou mais do que 15 classes, o valor exato depende de cada situação, ou seja, de quantos dados existem.
- Ter certeza de que cada dado se enquadre somente em 1 classe.
- Sempre que <u>possível</u>, as classes devem cobrir amplitudes iguais de valores.
- As **classes abertas**, como "menos de", "ou menos" ou "ou mais", quando temos valores muito pequenos ou muito grandes do que a maioria. Más, devemos utilizar com <u>cuidado</u> e <u>evitar sempre que possível!</u>



Exemplo: Usando a informação fornecida pela direção de um parque florestal, temos os dados de 110 tempos de espera simulados 76 em minutos entre erupções de um gêiser famoso do local. O menor valor ali é 33 e o maior 118, uma escolha para as classes pode ser com as dezenas, começando em 30 - 39, 40 - 49, com a última 110 - 119. Elas cobrem todos os valores, não se sobrepõe e possuem 83 mesmo tamanho.



Exemplo: Desta maneira, podemos montar a tabela:

Tempo de espera entre erupções (minutos)	Contagem		Freqüência
30-39	II .		2
40-49	II		2
50-59	IIII		4
60-69	HH HH HH IIII		19
70-79			24
80-89	三三五五五五五五五五五五五五五五五五五五五五五五五五五五五五五五五五五五五五五		39
90-99	W W W		15
100-109	III		3 2
110-119	П		2
		Total	110

Coluna da direita: frequência de classe;

Menor (como 30) e maior valor (como o 39): limites de classe;

Limites inferiores de classe: 30, 40, etc;

Limites superiores de classe: 39, 49, etc;

Se tivéssemos valores decimais, o agrupamento seria feito, o valor 30 acomodaria valores entre 29,5 até 30,5, então a classe 30 - 39, incluiria os valores de 29,5 até 39,5;

Fronteiras de classe: 29,5; 39,5; 49,6; etc;

Fronteira superior: 39,5 (1° classe);

Fronteira inferior: 39,5 (2° classe);

As fronteiras são sempre valores impossíveis!



- ★ Pontos médios de classe: média simples do valor inferior e superior, caso da classe 30 39, o ponto médio é (30 + 39)/2 = 34,5
- ★ Intervalo de classe ou intervalo de classe da distribuição: comprimento da classe ou amplitude dos valores que pode conter, dado pela diferença das fronteiras, caso da classe 30 - 39, intervalo é 39,5 - 29,5 = 10
- ★ Mais usual apresentar a distribuição de frequências como distribuição percentual, para tanto, dividimos cada frequência de classe pelo número total de itens agrupados e então multiplicar por 100, caso da classe 30 39, temos 2 de frequência, então (2/110)*100 = 1,818% = 1,82%



Exemplo: Vamos montar a tabela anterior com distribuição percentual.

```
1° classe: (2/110)*100 = 1,82%

2° classe: (2/110)*100 = 1,82%

3° classe: (4/110)*100 = 3,64%

4° classe: (19/110)*100 = 17,27%

5° classe: (24/110)*100 = 21,82%

6° classe: (39/110)*100 = 35,45%

7° classe: (15/110)*100 = 13,64%

8° classe: (3/110)*100 = 2,73%

9° classe: (2/110)*100 = 1,82%
```

Veja se somarmos todas percentagens, chegamos em 101,01%, o correto é sempre 100%, essa diferença é devido aos arredondamentos feitos.

Tempo de espera entre erupções (minutos)	Percentagem
30-39	1,82
40-49	1,82
50-59	3,64
60-69	17,27
70-79	21,82
80-89	35,45
90-99	13,64
100-109	2,73
110-119	1,82



★ Uma outra maneira de apresentar a tabela é utilizando a distribuição cumulativa, com "menos de", "ou menos", "mais de" ou "ou mais". Para isso, somamos as frequências de classe, partindo do topo ou da base.

"Menos de 30", poderia ser "29 ou menos" e assim por diante, nesse caso, chamamos de distribuição cumulativa do tipo "ou menos".

Tempo de espera entre erupções (minutos)	Freqüência cumulativa
Menos de 30	0
Menos de 40	2
Menos de 50	4
Menos de 60	8
Menos de 70	27
Menos de 80	51
Menos de 90	90
Menos de 100	105
Menos de 110	108
Menos de 120	110



- ★ No caso anterior, utilizamos a frequência dos dados, pode-se fazer o mesmo cumulativo, utilizando as frequências em porcentagem, assim teríamos uma distribuição percentual cumulativa, somando as porcentagens das frequências.
- ★ Se nossa distribuição for categórica (qualitativa), seguimos o mesmo método para as classes (quantas categorias), muitas vezes é prudente neste tipo de pesquisa ter a categoria "outros" ou "diversos". Muito cuidado com ambiguidades, classificar artigos em supermercados como "carnes", "congelados", "assados", onde entraria o item torta de carne congelada? Pensando em profissões, onde colocar administrador de fazenda, se tivéssemos na tabela "fazendeiros" e "administradores"?



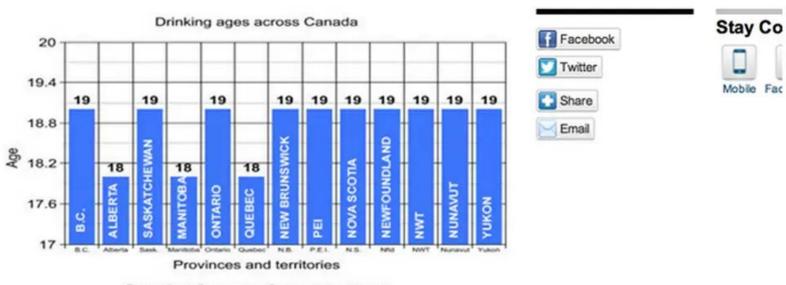
APRESENTAÇÕES GRÁFICAS

- ★ Apresentar dados em forma de gráficos é interessante?
- ★ Qual estilo utilizar?
- ★ Um gráfico irá sempre ajudar na compreensão da informação?

Drinking age will remain 19 in Saskatchewan



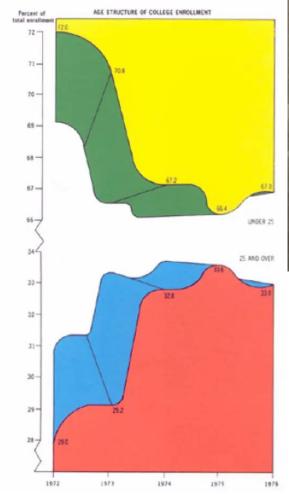
CBC News Posted: Mar 4, 2013 11:59 AM CST Last Updated: Mar 4, 2013 11:55 AM CST 25



Canadian Centre on Substance Abuse

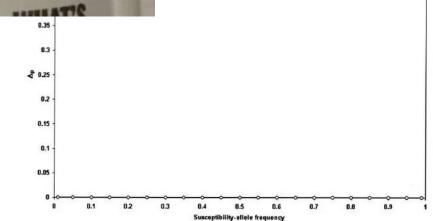
You have to be 19 in Saskatchewan to have a drink, while in Alberta and Manitoba, the drinking age 18. (CBC)

The Saskatchewan Party government has ruled out lowering the drinking age, four months after party members put the issue in the public eye.

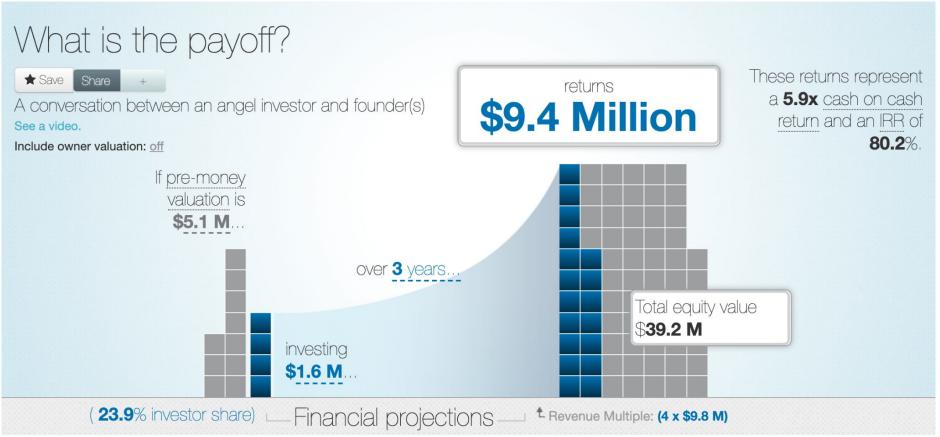




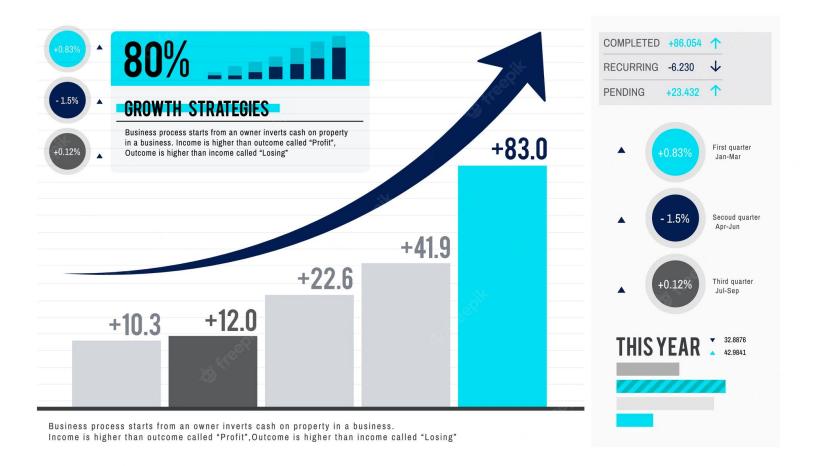










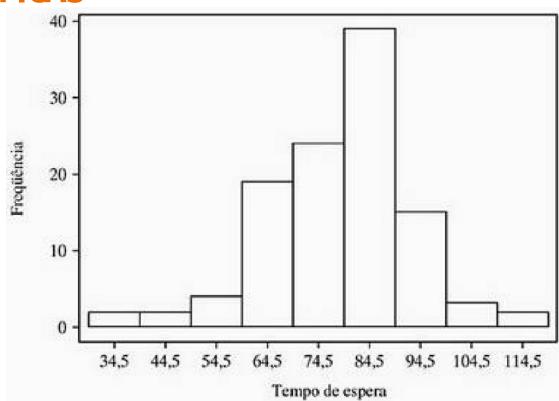




★ Histogramas: muito usado para as distribuições de frequência, nele ficam agrupadas medidas ou observações na escala horizontal, com retângulos que tem base igual ao intervalo de classe e alturas iguais às frequências de classe, na horizontal, podemos utilizar os pontos médios das classes, os limites da classe, as fronteiras ou outros valores. Se tivermos classes abertas não podemos utilizar e cuidado quando se tem classes com intervalos diferentes!

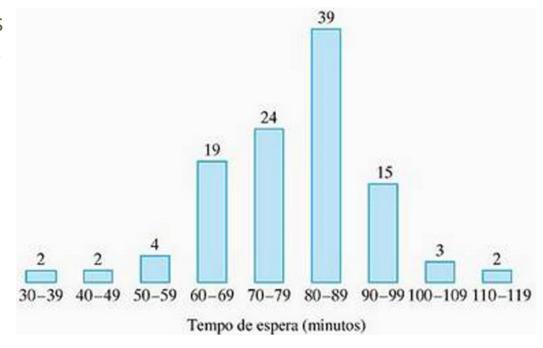


Tempo de espera entre erupções (minutos)		Freqüência
30-39		2
40-49		2
50-59		4
60-69		19
70-79		24
80-89		39
90-99		15
100-109		3
110-119		2
	Total	110





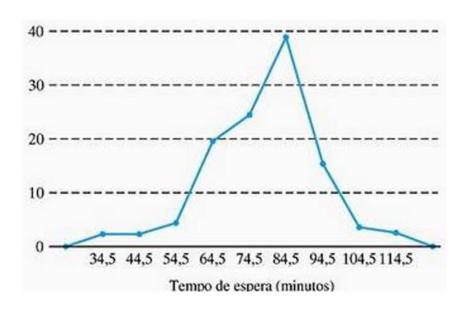
★ Gráficos de barras: algumas vezes também denominados histogramas, a diferença fica na escala horizontal que acaba sendo contínua.





★ Polígonos de frequência ou Gráfico de linhas:

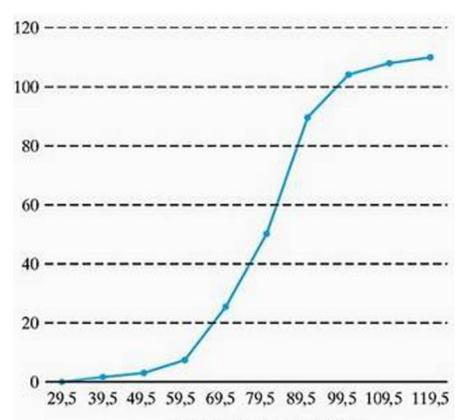
frequências de classe fazem par com os pontos médios das classes e então unidos por uma reta, coloca-se classes com frequência 0 nas duas extremidades, para que saia da reta horizontal.





★ Ogiva de frequência ou Gráfico de linhas com frequência acumulada:

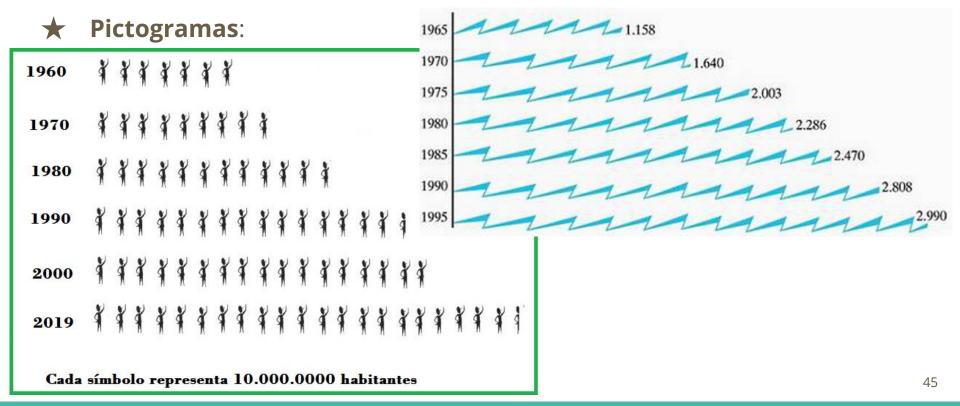
frequências acumuladas fazem par com as fronteiras de classes e então unidos por uma reta, coloca-se fronteira com frequência 0 na extremidade esquerda, para que saia da reta horizontal.



Planilha Aula 1:

Tempo de espera (minutos)







★ Gráficos de setores (pizza): muito utilizado para distribuições categóricas. Utiliza-se distribuição percentual e a relação que um círculo possui 360° então 360°/100% = 3,6° para cada 1%.





★ Exemplo: A tabela mostra (em milhares) a escolaridade de pessoas com filhos em determinado ano. Construa um gráfico de setores.

Ensino Médio incompleto	12.159
Ensino Médio completo	19.063
Ensino Superior incompleto	12.422
Ciclo básico do Ensino Superior	3.982
Ensino Superior completo	8.173
Pós-graduação	2.812
Section 1997 Contract	58.611

1°) Passar para porcentagem:

$$\frac{12.159}{58.611} \cdot 100\% = 20,75\%$$
 $\frac{3.982}{58.611} \cdot 100\% = 6,79\%$ $\frac{19.063}{58.611} \cdot 100\% = 32,52\%$ $\frac{8.173}{58.611} \cdot 100\% = 13,94\%$ $\frac{12.422}{58.611} \cdot 100\% = 21,19\%$ $\frac{2.812}{58.611} \cdot 100\% = 4,80\%$

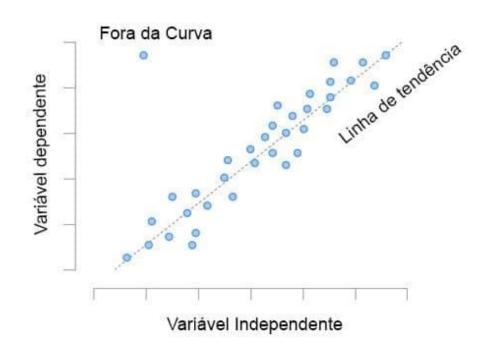


★ 2°) Passar para graus: multiplica-se a porcentagem por 3,6. Então:





★ Chamaremos os valores de x e y, são os dados emparelhados, par ordenado (x, y), como o ponto no plano cartesiano, gráfico de dispersão ou diagrama de dispersão, para procurar relações entre as variáveis x e y (se existir), ou seja, verificar se temos padrões.





★ Exemplo: Uma matéria-prima utilizada na produção de fibra sintética está armazenada em um local sem controle de umidade, na tabela temos as medidas x de umidade relativa do local e y de conteúdo de água em uma amostra da matéria-prima.

Construa um gráfico de dispersão.

X	у		
(Percentagem)	(Percentagem)		
36	12		
27	11		
24	10		
50	17		
31	10		
23	12		
45	18		
44	16		
43	14		
32	13		
19	11		
34	12		
38	17		
21	8		
16	7		



★ Exemplo: Os dados foram obtidos num estudo sobre a relação entre a resistência (em ohms) e o tempo (em minutos) que certos resistores sobrecarregados levam para falhar. Construa um gráfico de dispersão.

Resistência	Tempo de falha
x	у
33	39
36	36
30	34
44	51
34	36
25	21
40	45
28	25
40	45
46	36
42	39
48	41
47	45
25	21



4		40	39	32	23	37	34	32	28
\star	Exemplo : As notas na tabela foram	45	45	45	35	41	38	40	34
	obtidas por 40 alunos em ambas	27	24	42	36	35	33	37	37
	partes de um teste, com as notas de	42	39	44	42	34	30	47	45
	problemas pares denotadas por x e	42	29	41	35	38	40	44	40
	as notas de problemas ímpares por y.	49	40	48	45	42	34	35	35
	Escolhendo as 5 classes 26 - 30,	36	28	44	39	32	35	44	35
	31 - 35, 36 - 40, 41 - 45 e 46 - 50 para	39	39	40	28	38	27	43	38
	x e as 6 classes 21 - 25, 26 - 30,	43	38	50	48	36	37	37	35
	31 - 35, 36 - 40, 41 - 45 e 46 - 50 para	39	34	37	39	43	42	43	33

y, agrupe os dados em uma distribuição de frequência dupla e esboce um histograma tridimensional.

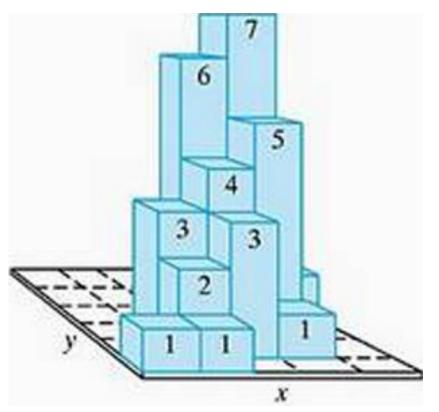


★ Fazendo a contagem, montamos a tabela:

		26-30	31-35	x 36-40	41-45	46-50
	21-25	1	1			
	26-30		2	3	1	
	31-35		3	4	5	
y	36-40			6	7	1
	41-45				3	2
	46-50					1

x	у	x	у	х	у	х	У
40	39	32	23	37	34	32	28
45	45	45	35	41	38	40	34
27	24	42	36	35	33	37	37
42	39	44	42	34	30	47	45
42	29	41	35	38	40	44	40
49	40	48	45	42	34	35	35
36	28	44	39	32	35	44	35
39	39	40	28	38	27	43	38
43	38	50	48	36	37	37	35
39	34	37	39	43	42	43	33





		26-30	31-35	x 36-40	41-45	46-50
	21-25	1	1			
	26-30		2	3	1	
	31-35		3	4	5	
у	36-40			6	7	1
	41-45				3	2
	46-50					1



★ Muito obrigado pela atenção!