

---

# Estatística e Probabilidade

## Bacharelado em Sistemas de Informação

Aula 3: Resumindo dados: Medidas de  
Dispersão  
Prof. Dr. Samuel Sanches

---

# MEDIDAS DE DISPERSÃO: AMPLITUDE

- ★ Os conjuntos de dados muitas vezes possuem certa **variabilidade**: dois pacientes tiveram os pulsos medidos, A, 72, 76 e 74 e o B, 72, 91 e 59, para os dois a média é 74, porém o B possui uma **variação** muito grande!
- ★ A **amplitude** nos ajuda a verificar essa **variação**, sendo definida como: **diferença entre o maior e o menor valor**.
- ★ Paciente A: Amplitude =  $76 - 72 = 4$ ; Paciente B: Amplitude =  $91 - 59 = 32$ .

# MEDIDAS DE DISPERSÃO: AMPLITUDE

★ Veja os dados:

Conjunto A:	5	18	18	18	18	18	18	18	18	18
Conjunto B:	5	5	5	5	5	18	18	18	18	18
Conjunto C:	5	6	8	9	10	12	14	15	17	18

Todos possuem amplitude de  $18 - 5 = 13$ , porém veja a dispersão (espaçamento entre valores), que é totalmente diferente!

- ★ **Amplitude interquartil:**  $Q3 - Q1$ . Para abranger aproximadamente 50% dos valores centrais.
- ★ **Amplitude semi-interquartil** ou **desvio quartil:**  $(Q3 - Q1)/2$

# MEDIDAS DE DISPERSÃO: DESVIO-PADRÃO E VARIÂNCIA

- ★ Uma das medidas de dispersão mais úteis!
- ★ Valores **concentrados** ao redor da **média**: dispersão **pequena**.
- ★ Valores **espalhados** ao redor da **média**: dispersão **alta**.
- ★ Quanto o valor está afastado da média (**desvio da média**):  $x_n - \bar{x}$
- ★ Então vamos utilizar o quadrado desse valor (para evitar valores negativos) somando todos resultados, para depois dividir pela quantidade n de dados (média) e calcular a raiz quadrada, para compensar o fato de ter elevado ao quadrado, temos o chamado **desvio da raiz dos quadrados médios**.

# MEDIDAS DE DISPERSÃO: DESVIO-PADRÃO E VARIÂNCIA

★ Temos o **desvio-padrão amostral**:

$$s = \sqrt{\frac{\sum (x - \bar{x})^2}{n - 1}}$$

$$s = \sqrt{\frac{S_{xx}}{n - 1}} \quad \text{onde} \quad S_{xx} = \sum x^2 - \frac{(\sum x)^2}{n}$$

★ Elevando ao quadrado,  $s^2$ , temos a chamada **variância amostral**.

★ Para populações, **desvio-padrão populacional**, temos a mesma expressão com modificações nas notações,  $s \rightarrow \sigma$ ,  $n \rightarrow N$ , média  $\rightarrow \mu$ . E a **variância população** dada por  $\sigma^2$

# MEDIDAS DE DISPERSÃO: DESVIO-PADRÃO E VARIÂNCIA

★ **Exemplo:** Um laboratório encontrou 8, 11, 7, 13, 10, 11, 7 e 9 bactérias em oito pessoas saudáveis. Calcule  $s$ .

$$\bar{x} = \frac{8 + 11 + 7 + 13 + 10 + 11 + 7 + 9}{8} = 9,5$$

$x$	$x - \bar{x}$	$(x - \bar{x})^2$
8	-1,5	2,25
11	1,5	2,25
7	-2,5	6,25
13	3,5	12,25
10	0,5	0,25
11	1,5	2,25
7	-2,5	6,25
9	-0,5	0,25
	0,0	32,00

$$s = \sqrt{\frac{32,00}{7}} = \sqrt{4,57} = 2,14$$

# MEDIDAS DE DISPERSÃO: DESVIO-PADRÃO E VARIÂNCIA

- ★ **Exemplo:** Um laboratório encontrou 8, 11, 7, 13, 10, 11, 7 e 9 bactérias em oito pessoas saudáveis. Calcule  $s$  (com a outra expressão).

$$\sum x = 8 + 11 + 7 + \dots + 7 + 9$$

$$= 76$$

$$\sum x^2 = 64 + 121 + 49 + 169 + 100 + 121 + 49 + 81$$

$$= 754$$

$$S_{xx} = 754 - \frac{(76)^2}{8} = 32$$

$$s = \sqrt{\frac{32}{7}} = 2,14$$

# APLICAÇÕES

- ★ **Teorema de Tchebichev:** Para qualquer conjunto de dados (população ou amostra) e qualquer constante  $k$  maior do que 1, a proporção dos dados que devem estar a menos de  $k$  desvios-padrão de qualquer um dos dois lados da média é pelo menos  $1 - 1/k^2$
- ★ Isso nos permite afirmar coisas como 75% dos valores de qualquer conjunto de dados devem estar a pelo menos 2 desvios-padrão de qualquer um dos dois lados da média ( $1 - 1/2^2 = 3/4 = 0,75$ ). 96% dos valores estão a 5 desvios-padrão ( $1 - 1/5^2 = 24/25 = 0,96$ ) e 99% a menos de 10 desvios-padrão ( $1 - 1/10^2 = 99/100 = 0,99$ ).



# APLICAÇÕES


★ **Exemplo:** Um estudo sobre queijos mostrou que, em média, uma fatia de 30 gramas contém 3,50 gramas de gordura com um desvio-padrão de 0,04 gramas de gordura. **a)** De acordo com o teorema de Tchebichev, pelo menos qual percentagem de uma fatia de 30 gramas desse tipo de queijo deve ter um conteúdo de gordura entre 3,38 e 3,62 gramas de gordura? **b)** De acordo com o teorema, entre quais valores deve estar o conteúdo de gordura de pelo menos 93,75% das fatias de 30 gramas desse tipo de queijo?

**a)**  $3,62 - 3,50 = 0,12$ , então  $k \cdot 0,04 = 0,12$  (para descobrir quantos desvios-padrão temos),  $k = 3$ , assim,  $1 - 1/3^2 = 8/9 = 0,889$ , ou seja, 88,9% possuem o indicado.

**b)**  $1 - 1/k^2 = 0,9375$ ,  $1/k^2 = 1 - 0,9375 = 0,0625$ ,  $k^2 = 1/0,0625 = 16$ ,  $k = 4$ , então, 93,75% possuem entre  $3,50 - 4 \cdot (0,04) = 3,34$  e  $3,50 + 4 \cdot (0,04) = 3,66$  gramas de gordura.

# APLICAÇÕES

- ★ Possui problemas, temos uma regra **empírica** (registrada a partir de dados) que caso a distribuição siga o formato de sino (**distribuição normal**), podemos afirmar:



**Cerca de 68% dos valores estão a menos de um desvio-padrão da média, isto é, entre  $\bar{x} - s$  e  $\bar{x} + s$ .**

**Cerca de 95% dos valores estão a menos de dois desvios-padrão da média, isto é, entre  $\bar{x} - 2s$  e  $\bar{x} + 2s$ .**

**Cerca de 99,7% dos valores estão a menos de três desvios-padrão da média, isto é, entre  $\bar{x} - 3s$  e  $\bar{x} + 3s$ .**

# APLICAÇÕES

★ **Exemplo:** Usamos os dados de tempo de espera de erupções, onde a média encontrada foi de 78,59 e aqueles dados possuem desvio-padrão de 14,35. Utilizando esses valores, determine qual percentagem está a menos de três desvios-padrão da média.

Pontos médios de classe	Frequência	
$x$	$f$	$x \cdot f$
34,5	2	69,0
44,5	2	89,0
54,5	4	218,0
64,5	19	1.225,5
74,5	24	1.788,0
84,5	39	3.295,5
94,5	15	1.417,5
104,5	3	313,5
114,5	2	229,0
	110	8.645,0

Então:  $78,59 - 3 \cdot (13,35) = 35,54$  (limite inferior),  $78,59 + 3 \cdot (13,35) = 121,64$  (limite superior), temos 2 valores menores que 35,54 e nenhum acima de 121, então  $110 - 2 = 108$  dos valores estão compreendidos no intervalo, ou seja,  $(108/110) \cdot 100 = 98,2\%$  dos tempos caem a menos de 3 desvios-padrão da média (próximo do valor de 99,7% do slide anterior, vale lembrar que essa distribuição não tem forma de sino).

# APLICAÇÕES

- ★ Para compararmos dados aparentemente diferentes, usamos **unidades padronizadas** (ou **escores**),  $z$ .

$$z = \frac{x - \bar{x}}{s} \quad \text{ou} \quad z = \frac{x - \mu}{\sigma}$$

- ★ Dois exames, vocabulário obteve 66 e gramática 80, aparentemente melhor em gramática, média turma 51 com desvio 12 em vocabulário e média 72 com desvio 16 em gramática.

Vocabulário:  $(66 - 51)/12 = 1,25$  desvios-padrão acima da média.

Gramática:  $(80 - 72)/16 = 0,50$  desvios-padrão acima da média.

Então, veja que ele está melhor do que a turma em vocabulário (mais longe da média).

# APLICAÇÕES

★ **Exemplo:** Uma faixa etária possui massa média de 56 kg, com desvio-padrão de 6 kg, outra faixa etária possui massa média 82 kg com desvio-padrão de 9 kg. Se uma pessoa da 1º faixa possui 66 kg e outra da 2º faixa possui 96 kg, qual dos dois, relativamente a massa média de sua faixa etária, está com maior excesso de massa?

$$1^\circ \text{ faixa: } (66 - 56)/6 = 1,66$$

$$2^\circ \text{ faixa: } (96 - 82)/9 = 1,55$$

Então, a pessoa da 1º faixa está com excesso relativo a sua faixa etária.

# APLICAÇÕES

- ★ O desvio-padrão depende das unidades de medida, por exemplo um objeto possui desvio-padrão de 0,1 grama, não temos como saber se isso é muito ou se é pouco, assim podemos usar uma **medida de dispersão relativa**, como o **coeficiente de dispersão**:

$$V = \frac{s}{\bar{x}} \cdot 100\% \quad \text{ou} \quad V = \frac{\sigma}{\mu} \cdot 100\%$$

- ★ Ele nos informa o desvio-padrão como uma porcentagem da medida em média.

# APLICAÇÕES

- ★ **Exemplo:** Várias medições efetuadas com um micrômetro, acusaram média de 2,49 mm e desvio-padrão de 0,012 mm, com um outro micrômetro e um outro objeto teve 0,75 cm de média e desvio-padrão de 0,002 cm. Qual dos dois micrômetros é mais preciso?

Coeficiente de dispersão:

$$\frac{0,012}{2,49} \cdot 100 \approx 0,48\% \quad \text{e} \quad \frac{0,002}{0,75} \cdot 100 \approx 0,27\%$$

Observe que o 2º possui menos variação, então é mais preciso.

# DADOS AGRUPADOS

- ★ Como temos uma perda de informação para cada dado, os itens dentro de uma mesma classe corresponderão ao ponto médio da classe. Então soma de todas medidas:

$$\sum x \cdot f = x_1 f_1 + x_2 f_2 + \cdots + x_k f_k$$

- ★ Soma de seus quadrados:

$$\sum x^2 \cdot f = x_1^2 f_1 + x_2^2 f_2 + \cdots + x_k^2 f_k$$

- ★ Desvio-padrão para dados amostrais agrupados:

$$s = \sqrt{\frac{S_{xx}}{n-1}} \quad \text{onde} \quad S_{xx} = \sum x^2 \cdot f - \frac{(\sum x \cdot f)^2}{n}$$



# DADOS AGRUPADOS

★ **Exemplo:** Com os dados do tempo de espera entre erupções (tabela ao lado), calcule o desvio-padrão.

$x$	$f$	$x \cdot f$	$x^2 \cdot f$
34,5	2	69	2.380,5
44,5	2	89	3.960,5
54,5	4	218	11.881
64,5	19	1.225,5	79.044,75
74,5	24	1.788	133.206
84,5	39	3.295,5	278.469,75
94,5	15	1.417,5	133.953,75
104,5	3	313,5	32.760,75
114,5	2	229	26.220,5
	110	8.645	701.877,5


Pontos médios de classe $x$	Frequência $f$	$x \cdot f$
34,5	2	69,0
44,5	2	89,0
54,5	4	218,0
64,5	19	1.225,5
74,5	24	1.788,0
84,5	39	3.295,5
94,5	15	1.417,5
104,5	3	313,5
114,5	2	229,0
	110	8.645,0

$$S_{xx} = 701.877,5 - \frac{(8.645)^2}{110} \approx 22.459,1$$


$$s = \sqrt{\frac{22.459,1}{109}} \approx 14,35$$

# DESCRIÇÕES ESTATÍSTICAS

- ★ Distribuição **perfeitamente** simétrica:  
Distribuição em forma de sino.



- ★ Distribuição **negativamente** assimétrica:  
"cauda" à esquerda.




- ★ Distribuição **positivamente** assimétrica:  
"cauda" à direita



# MEDIDAS DE ASSIMETRIA

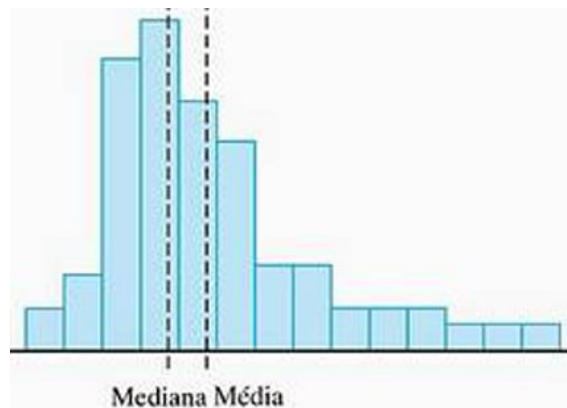
★ Média e mediana coincidem: simetria perfeita.



★ Assimetria positiva: média é maior que a mediana e Assimetria negativa: média é menor que a mediana.

★ **Coeficiente de assimetria de Pearson:**

$$SK = \frac{3 (\text{média} - \text{mediana})}{\text{desvio-padrão}}$$




$SK = 0 \rightarrow$  simetria perfeita, SK deve cair entre -3 e 3.

# MEDIDAS DE ASSIMETRIA

- ★ **Exemplo:** Calcule SK para a distribuição de tempos de espera entre as erupções, onde temos média de 78,59, mediana de 80,53 e desvio-padrão de 14,35.


$$SK = \frac{3(78,59 - 80,53)}{14,35} \approx -0,41$$

Simetria negativa (fraca/pequena), veja o histograma.



# MEDIDAS DE ASSIMETRIA

- ★ Conjunto pequeno de dados, histograma não é boa escolha, gráfico de caixa nos trás mais informações, a partir da posição da mediana em relação aos dois quartis  $Q_1$  e  $Q_3$ .



- ★ Reta da mediana está no centro ou próximo, temos uma boa simetria, muito à esquerda, simetria positiva, muito à direita, simetria negativa. Bem como as retas de menor e maior valor, quanto mais diferentes, mais assimétrico.

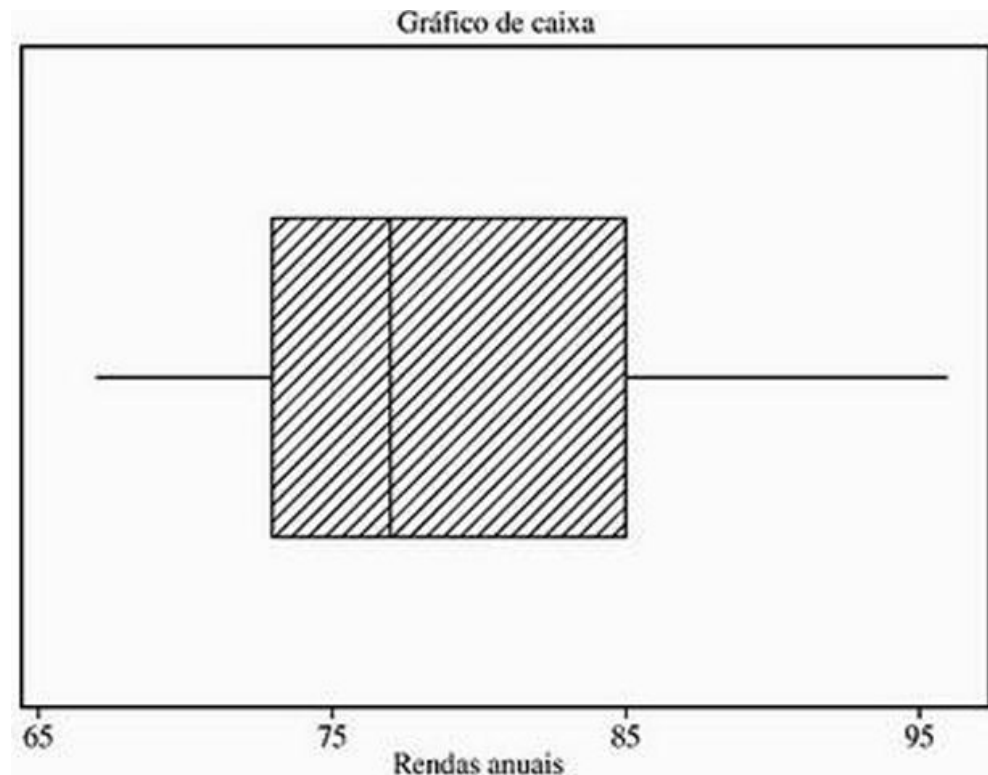
# MEDIDAS DE ASSIMETRIA

★ **Exemplo:** Os dados representam as rendas anuais de quinze contadores em milhares de unidades monetárias: 88, 77, 70, 80, 74, 82, 85, 96, 76, 67, 80, 75, 73, 93 e 72. Esboce um gráfico de caixa e use-o para determinar a simetria ou a falta de simetria dos dados.

Ordem: 67, 70, 72, 73, 74, 75, 76, 77, 80, 80, 82, 85, 88, 93, 96, menor 67, maior 96, mediana 77 (8º valor de qualquer lado), Q1 é 73 (4º valor a partir da esquerda), Q3 é 85 (4º valor a partir da direita).


# MEDIDAS DE ASSIMETRIA

★ **Exemplo:** Temos tendência que os dados são negativamente assimétricos, a reta mediana está à esquerda e a reta da direita é maior.



# MEDIDAS DE ASSIMETRIA

★ Distribuição em forma de J invertido:



★ Distribuição em forma de U:





# EXERCÍCIOS

## ★ Lista 1 de Exercícios → Parte 2

[https://drive.google.com/file/d/1f755nMDqpElkcHnFF49CjbAfw8CvWICS/view?usp=share link](https://drive.google.com/file/d/1f755nMDqpElkcHnFF49CjbAfw8CvWICS/view?usp=share_link)

★ Muito obrigado pela atenção!